

大数据技术及应用

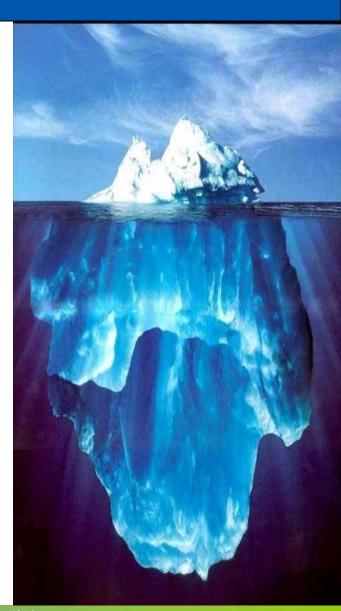
第三章 分布式文件系统HDFS

石家庄铁道大学

信息科学与技术学院

提纲

- 3.1 分布式文件系统
- 3.2 HDFS简介
- 3.3 HDFS相关概念
- 3.4 HDFS体系结构
- 3.5 HDFS存储原理
- 3.6 HDFS数据读写过程
- 3.7HDFS编程实践

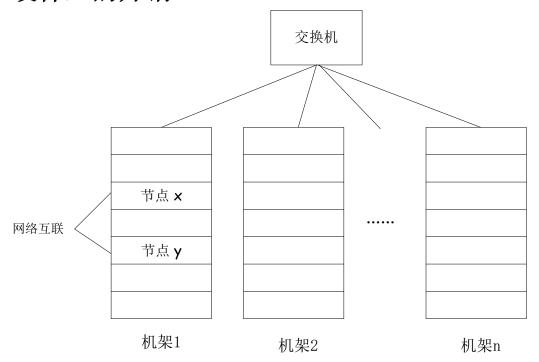


3.1 分布式文件系统

- 3.1.1 计算机集群结构
- 3.1.2 分布式文件系统的结构

3.1.1计算机集群结构

- •分布式文件系统把文件分布存储到多个计算机节点上,成千上万的计算机节点构成计算机集群
- •与之前使用多个处理器和专用高级硬件的并行化处理装置不同的是,目前的分布式文件系统<u>所采用的计算机集群,都是由普通硬件构成的</u>,这就大大降低了硬件上的开销



节点放机架上, 每个机架放8-64 个节点,通过网 络互联。

图3-1 计算机集群的基本架构

3.1.2分布式文件系统的结构

Windows/linux:把磁盘空间划分为每512字节一组,称为"磁盘块",是文件系统读写操作的最小单位,BLOCK是磁盘块的整倍数

 分布式文件系统HDFS: 块默认大小64MB。如果 一个文件小于数据块的大小,只占用实际大小的 空间。

3.1.2分布式文件系统的结构

分布式文件系统在物理结构上是由计算机集群中的多个节点构成的, 节点分为两类,一类叫"主节点"(Master Node)或称为"名称结点" (NameNode) , 另一类叫"从节点"(Slave Node)或称为"数据

节点"(DataNode)。

负责文件和目录的创建、删除和重命名等 客户端 访问请求 访问请求 负责数据的 主节点 客户端 存储和读取 读 写 写 数据节点 数据节点 复制 文件块 机架1 机架n

数据读、存 数据块操作

图3-2 大规模文件系统的整体结构

3.2 HDFS简介

HDFS要实现以下目标:

- ●兼容廉价的硬件设备
- ●流数据读写
- ●大数据集
- ●简单的文件模型
- ●强大的跨平台兼容性

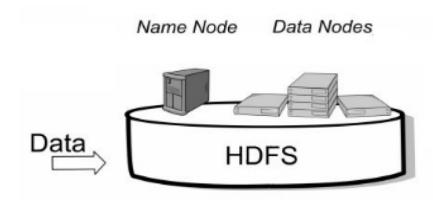
HDFS特殊的设计,在实现上述优良特性的同时,也使得自身具有一些应用局限性,主要包括以下几个方面:

- ●不适合低延迟数据访问
- ●无法高效存储大量小文件
- ●不支持多用户写入及任意修改文件

3.3.1块

- ▶HDFS默认一个块64MB,一个文件被分成多个块,以块作为存储单位,块的大小远远大于普通文件系统,可以最小化寻址开销。
- ▶HDFS采用抽象的块概念可以带来以下几个明显的好处:
- ●支持大规模文件存储:文件以块为单位进行存储,一个大规模文件可以被分拆成若干个文件块,不同的文件块可以被分发到不同的节点上,因此,一个文件的大小不会受到单个节点的存储容量的限制,可以远远大于网络中任意节点的存储容量
- ●简化系统设计:首先,简化了存储管理,因为文件块大小是固定的,这样就可以很容易计算出一个节点可以存储多少文件块;其次,方便了元数据的管理,元数据不需要和文件块一起存储,可以由其他系统负责管理元数据
- ●适合数据备份:每个文件块都可以冗余存储到多个节点上, 大大提高了系统的容错性和可用性。

HDFS主要组件的功能



metadata

File.txt= Blk A: DN1, DN5, DN6

Blk B: DN7, DN1, DN2

Blk C:

DN5, DN8,DN9

NameNode	DataNode
• 存储元数据	• 存储文件内容
•元数据保存在内存中	•文件内容保存在磁盘
• 保存文件,block ,datanode 之间的映射关系	•维护了block id到datanode本 地文件的映射关系

《大数据技术及应用》

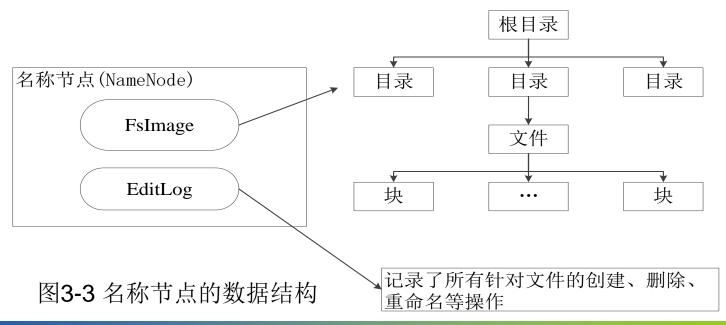
名称节点的数据结构

•名称节点NameNode负责管理分布式文件系统的命名空间Namespace,保存了两个核心的数据结构,即FsImage和EditLog:

FsImage维护文件系统树以及文件树中所有的文件和文件夹的元数据。

操作日志文件EditLog中记录了所有对文件的操作(创建/删除/重命名)。

•名称节点记录了每个文件中各个块所在的数据节点的位置信息。



《大数据技术及应用》

FsImage文件

- •FsImage文件包含文件系统中所有目录和文件inode的序列化形式。每个inode是一个文件或目录的元数据的内部表示,包含信息:文件的复制等级、修改和访问时间、访问权限、块大小以及组成文件的块。对于目录,则存储修改时间、权限和配额元数据
- •FsImage文件没有记录块存储在哪个数据节点。而是由名称节点把这些映射保留在内存中,当数据节点加入HDFS集群时,数据节点会把自己所包含的块列表告知给名称节点,此后会定期执行这种告知操作,以确保名称节点的块映射是最新的。

名称节点的启动

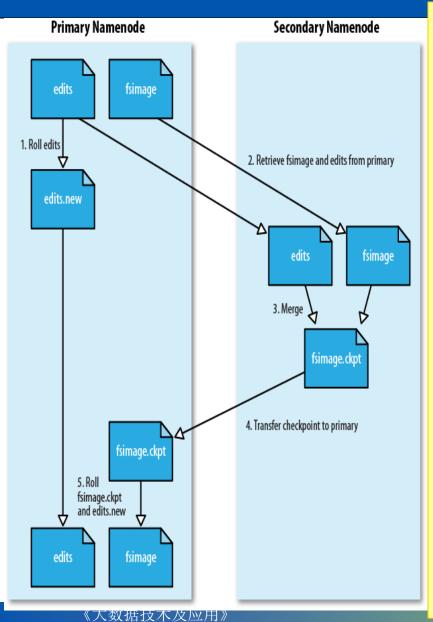
- ▶ 在名称节点启动的时候,它会将FsImage文件中的内容加载到内存中,之后再执行EditLog文件中的各项操作,使内存中的元数据和实际的同步,存在内存中的元数据支持客户端的读操作。
- ▶一旦在内存中成功建立文件系统元数据的映射,则创建一个新的FsImage文件和一个空的EditLog文件。
- ▶ 名称节点起来之后,HDFS中的更新操作会重新写到EditLog 文件中,因为FsImage文件一般都很大(GB级别的很常见), 如果所有的更新操作都往FsImage文件中添加,这样会导致系 统运行的十分缓慢,但是,如果往EditLog文件里面写就不会这 样,因为EditLog 要小很多。每次执行写操作之后,且在向客户 端发送成功代码之前,edits文件都需要同步更新。

名称节点运行期间EditLog不断变大的问题

- ▶在名称节点运行期间,HDFS的所有更新操作都是直接写到 EditLog中,久而久之, EditLog文件将会变得很大。
- ▶虽然这对名称节点运行时候是没有什么明显影响的,但是,当名称节点重启的时候,名称节点需要先将FsImage里面的所有内容映像到内存中,然后再一条一条地执行EditLog中的记录,当EditLog文件非常大的时候,会导致名称节点启动操作非常慢,而在这段时间内HDFS系统处于安全模式,一直无法对外提供写操作,影响了用户的使用

如何解决?答案是: SecondaryNameNode第二名称节点

第二名称节点是HDFS架构中的一个组成部分,它是用来保存名称节点中对HDFS 元数据信息的备份,并减少名称节点重启的时间。 SecondaryNameNode一般是单独运行在一台机器上。



SecondaryNameNode的工作情况:

- (1) SecondaryNameNode会定期和NameNode通信,请求其停止使用EditLog文件,暂时将新的写操作写到一个新的文件edit.new上来,这个操作是瞬间完成,上层写日志的函数完全感觉不到差别;
- (2) SecondaryNameNode通过HTTP GET方式从NameNode上获取到FsImage和EditLog文件,并下载到本地的相应目录下; (3) SecondaryNameNode将下载下来的FsImage载入到内存,然后一条一条地执行EditLog文件中的各项更新操作,使得内存中的FsImage保持最新; 这个过程就是EditLog和FsImage文件合并;
- (4) SecondaryNameNode执行完(3) 操作之后,会通过post方式将新的FsImage文件发送到NameNode节点上;
- (5) NameNode将从SecondaryNameNode接收到的新的FsImage替换旧的FsImage文件,同时将edit.new替换EditLog文件,通过这个过程EditLog就变小了

数据节点(DataNode)

•数据节点是分布式文件系统HDFS的工作节点,负责数据的存储和读取,会根据客户端或者是名称节点的调度来进行数据的存储和检索,并且向名称节点定期发送自己所存储的块的列表。

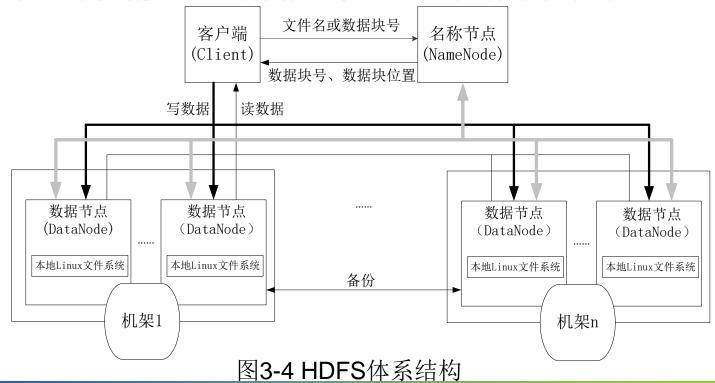
•每个数据节点中的数据会被保存在各自节点的本地Linux文件系统中。

3.4 HDFS体系结构

- 3.4.1 HDFS体系结构概述
- 3.4.2 HDFS命名空间管理
- 3.4.3 通信协议
- 3.4.4 客户端
- 3.4.5 HDFS体系结构的局限性

3.4.1HDFS体系结构概述

HDFS采用了主从(Master/Slave)结构模型,一个HDFS集群包括一个名称节点NameNode和若干个数据节点DataNode。名称节点作为中心服务器,负责管理文件系统的命名空间及客户端对文件的访问。集群中的数据节点一般是一个节点运行一个数据节点进程,负责处理文件系统客户端的读/写请求,在名称节点的统一调度下进行数据块的创建、删除和复制等操作。每个数据节点的数据实际上是保存在本地Linux文件系统中的。



3.4.2HDFS命名空间管理

- HDFS的命名空间包含目录、文件和块。
- 在HDFS1.0体系结构中,在整个HDFS集群中只有一个命名空间,并且只有唯一一个名称节点,该节点负责对这个命名空间进行管理。
- HDFS使用的是传统的分级文件体系,因此,用户可以像使用普通文件系统一样,创建、删除目录和文件,在目录间转移文件,重命名文件等。

3.4.3通信协议

- HDFS是一个部署在集群上的分布式文件系统,因此,很多数据需要通过网络进行传输。
- · 所有的HDFS通信协议都是构建在TCP/IP协议基础之上的。
- 客户端通过一个可配置的端口向名称节点主动发起TCP连接,并使用客户端协议与名称节点进行交互。
- 名称节点和数据节点之间则使用数据节点协议进行交互。
- 客户端与数据节点的交互是通过RPC(Remote Procedure Call)来实现的。在设计上,名称节点不会主动发起RPC,而是响应来自客户端和数据节点的RPC请求。

3.4.4客户端

- 客户端是用户操作HDFS最常用的方式,HDFS在部署时都提供了客户端。
- HDFS客户端是一个库,暴露了HDFS文件系统接口,这些接口隐藏了HDFS实现中的大部分复杂性。
- 严格来说,客户端并不算是HDFS的一部分。
- 客户端可以支持打开、读取、写入等常见的操作,并且 提供了类似Shell的命令行方式来访问HDFS中的数据。
- 此外,HDFS也提供了Java API,作为应用程序访问文件系统的客户端编程接口。

3.4.5HDFS体系结构的局限性

HDFS只设置唯一一个名称节点,这样做虽然大大简化了系统设计,但也带来了一些明显的局限性,具体如下:

- (1)命名空间的限制:名称节点是保存在内存中的,因此,名称节点能够容纳的对象(文件、块)的个数会受到内存空间大小的限制。
- (2)性能的瓶颈:整个分布式文件系统的吞吐量,受限于单个名称节点的吞吐量。
- (3)隔离问题:由于集群中只有一个名称节点,只有一个命名空间,因此,无法对不同应用程序进行隔离。
- (4)集群的可用性:一旦这个唯一的名称节点发生故障,会导致整个集群变得不可用。

3.5 HDFS存储原理

- 3.5.1 冗余数据保存
- 3.5.2 数据存取策略
- 3.5.3 数据错误与恢复

3.5.1冗余数据保存

作为一个分布式文件系统,为了保证系统的容错性和可用性,HDFS采用了多副本方式对数据进行冗余存储,通常一个数据块的多个副本会被分布到不同的数据节点上,这种多副本方式具有以下几个优点:

- (1) 加快数据传输速度
- (2) 容易检查数据错误
- (3) 保证数据可靠性

数据块1被分别存放 到数据节点A和C上

数据块2被存放在数据节点A和B上。

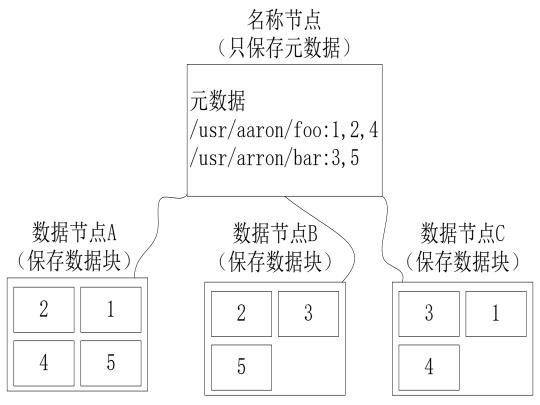
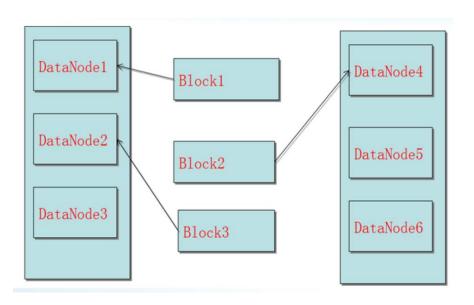


图3-5 HDFS数据块多副本存储

3.5.2数据存取策略

1.数据存放

- ▶第一个副本:放置在上传文件的数据节点;如果是集群外提交,则随机挑选一台磁盘不太满、CPU不太忙的节点;
- ▶第二个副本: 放置在与第一个副本不同的机架的节点上;
- ▶第三个副本: 与第一个副本相同机架的其他节点上;
- ▶更多副本: 随机节点。



Block的副本放置策略

3.5.2数据存取策略

- 2. 数据读取
- •HDFS提供了一个API可以确定一个数据节点所属的机架ID,客户端也可以调用API获取自己所属的机架ID;
- •当客户端读取数据时,从名称节点获得数据块不同副本的存放位置列表,列表中包含了副本所在的数据节点,可以调用API来确定客户端和这些数据节点所属的机架ID,当发现某个数据块副本对应的机架ID和客户端对应的机架ID相同时,就优先选择该副本读取数据,如果没有发现,就随机选择一个副本读取数据。

3.5.2数据存取策略

- 3. 数据复制
- •HDFS采用流水线复制的策略。
- •HDFS将文件写入本地,分成多个块。每个块都向名称节点发起请求,得到数据节点列表。连接第一个节点,写入;请求连接第二节点,写入.....

3.5.3数据错误与恢复

HDFS具有较高的容错性,可以兼容廉价的硬件,它把硬件出错看作一种常态,而不是异常,并设计了相应的机制检测数据错误和进行自动恢复,主要包括以下几种情形:名称节点出错、数据节点出错和数据出错。

1. 名称节点出错

名称节点保存了所有的元数据信息,其中,最核心的两大数据结构是FsImage和Editlog,如果这两个文件发生损坏,那么整个HDFS实例将失效。因此,HDFS设置了备份机制,把这些核心文件同步复制到备份服务器SecondaryNameNode上。当名称节点出错时,就可以根据备份服务器SecondaryNameNode中的FsImage和Editlog数据进行恢复。

3.5.3数据错误与恢复

2. 数据节点出错

- •每个数据节点会定期向名称节点发送"心跳"信息,向名称节点报告自己的状态;
- •当数据节点发生故障,或者网络发生断网时,名称节点就无法收到来自一些数据节点的心跳信息,这时,这些数据节点就会被标记为"宕机",节点上面的所有数据都会被标记为"不可读",名称节点不会再给它们发送任何I/O请求;
- •这时,有可能出现一种情形,即由于一些数据节点的不可用,会导致一些 数据块的副本数量小于冗余因子;
- •名称节点会定期检查这种情况,一旦发现某个数据块的副本数量小于冗余因子,就会启动数据冗余复制,为它生成新的副本;
- •HDFS和其它分布式文件系统的最大区别就是可以调整冗余数据的位置。

《大数据技术及应用》

3.5.3数据错误与恢复

- 3. 数据出错
- •网络传输和磁盘错误等因素,都会造成数据错误;
- •客户端在读取到数据后,会采用md5和sha1对数据块进行校验,以确定读取到正确的数据;
- •在文件被创建时,客户端就会对每一个文件块进行信息摘录,并把 这些信息写入到同一个路径的隐藏文件里面;
- 当客户端读取文件的时候,会先读取该信息文件,然后,利用该信息文件对每个读取的数据块进行校验,如果校验出错,客户端就会请求到另外一个数据节点读取该文件块,并且向名称节点报告这个文件块有错误,名称节点会定期检查并且重新复制这个块。

- 3.6.1 读数据的过程
- 3.6.2 写数据的过程

读取文件

```
import java.io.BufferedReader;
import java.io.InputStreamReader;
import org. apache. hadoop. conf. Configuration;
import org. apache. hadoop. fs. FileSystem;
import org. apache. hadoop. fs. Path;
import org. apache. hadoop. fs. FSDataInputStream;
public class Chapter3 {
    public static void main(String[] args) {
        try ·
            Configuration conf = new Configuration();
            FileSystem fs = FileSystem.get(conf);
            Path filename = new Path ("hdfs://localhost:9000/user/hadoop/
test. txt");
            FSDataInputStream is = fs. open(filename);
            BufferedReader d = new BufferedReader (new InputStreamReader (i
s));
            String content = d. readLine(); //读取文件一行
            System. out. println(content);
            d. close(); // 关闭文件
            fs. close(); //美聞hdfs
          catch (Exception e) {
            e.printStackTrace();
```

写入文件

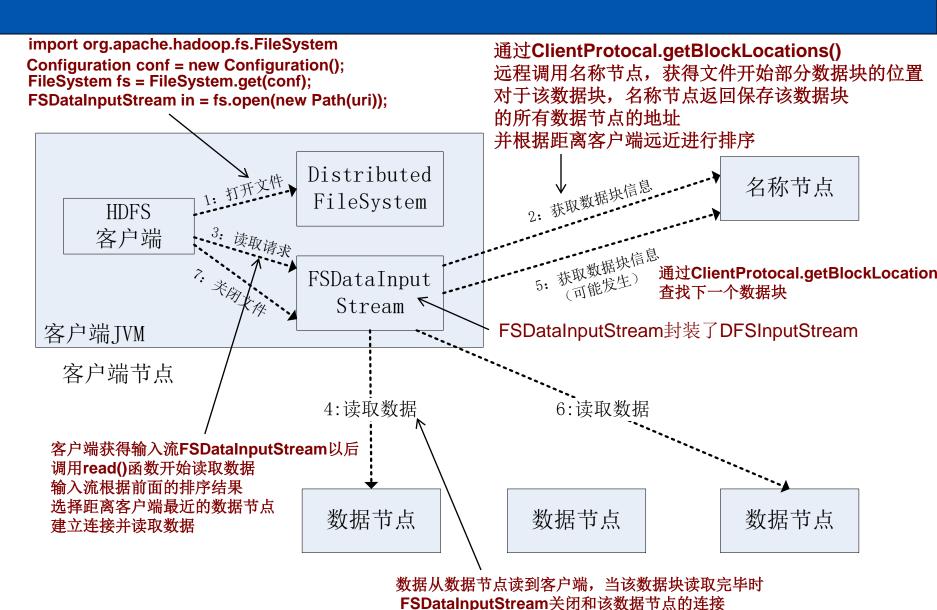
```
import org.apache.hadoop.conf.Configuration
import org.apache.hadoop.fs.FileSystem
import org.apache.hadoop.fs.FSDataOutputStream
import org.apache.hadoop.fs.Path
public class Chapter3 {
  public static void main(String[] args) {
    try {
       Configuration conf = new Configuration();
       FileSystem fs = FileSystem.get(conf);
       byte[] buff = "Hello world".getBytes(); // 要写入的内容
       String filename = "hdfs://localhost:9000/user/hadoop/test.txt"; //要写入的文件名
       FSDataOutputStream os = fs.create(new Path(filename));
       os.write(buff, 0, buff.length);
       System.out.println("Create:"+ filename);
    } catch (Exception e) {
       e.printStackTrace();
```

- •FileSystem是一个通用文件系统的抽象基类,可以被分布式文件系统继承,所有可能使用Hadoop文件系统的代码,都要使用这个类;
- •Hadoop为FileSystem这个抽象类提供了多种具体实现;
- •DistributedFileSystem就是FileSystem在HDFS文件系统中的具体实现;
- •FileSystem的open()方法返回的是一个输入流FSDataInputStream对象,在HDFS文件系统中,具体的输入流就是DFSInputStream; FileSystem中的create()方法返回的是一个输出流FSDataOutputStream对象,在HDFS文件系统中,具体的输出流就是DFSOutputStream。

```
Configuration conf = new Configuration();
FileSystem fs = FileSystem.get(conf);
FSDataInputStream in = fs.open(new Path(uri));
FSDataOutputStream out = fs.create(new Path(uri));
```

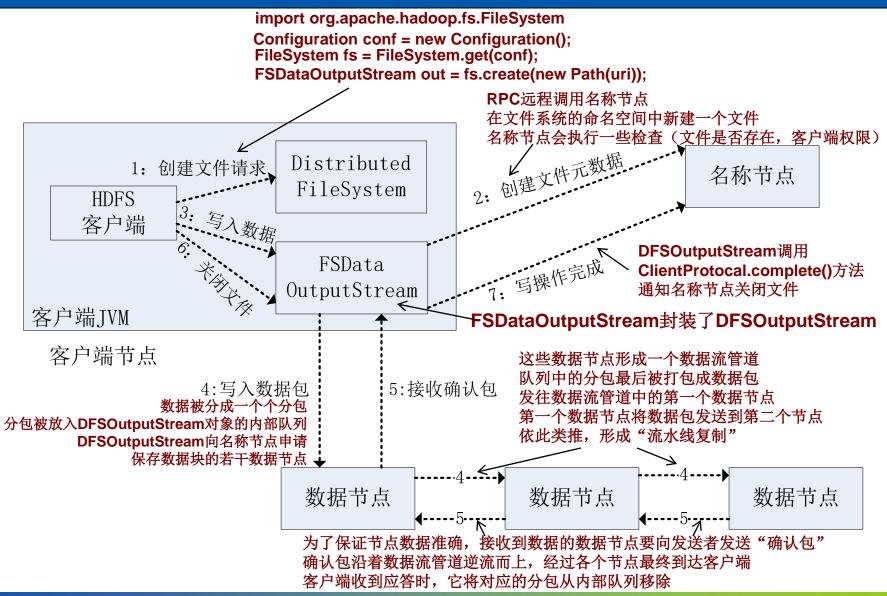
注意:创建一个Configuration对象时,其构造方法会默认加载工程项目下两个配置文件,分别是hdfs-site.xml以及core-site.xml,这两个文件中会有访问HDFS所需的参数值,主要是fs.defaultFS,指定了HDFS的地址(比如hdfs://localhost:9000),有了这个地址客户端就可以通过这个地址访问HDFS了

3.6.1读数据的过程



《大数据技术及应用》

3.6.2写数据的过程



3.7 HDFS编程实践

Hadoop提供了关于HDFS在Linux操作系统上进行文件操作的常用 Shell命令以及Java API。同时还可以利用Web界面查看和管理 Hadoop文件系统。

备注: Hadoop安装成功后,已经包含HDFS和MapReduce,不需要额外安装。而HBase等其他组件,则需要另外下载安装。

在学习HDFS编程实践前,我们需要启动Hadoop。执行如下命令:

```
$ cd /usr/local/hadoop
$ ./bin/hdfs namenode -format #格式化hadoop的hdfs文件系统
$ ./sbin/start-dfs.sh #启动hadoop
```

《大数据技术及应用》 信息科学与技术学院 36

3.7.1HDFS常用命令

HDFS有很多shell命令,

fs命令: 查看HDFS文件系统的目录结构、上传和下载数据、创建文件等。

该命令的用法为:

hadoop fs [genericOptions] [commandOptions]

备注: Hadoop中有三种Shell命令方式:

- •hadoop fs适用于任何不同的文件系统,比如本地文件系统和HDFS文件系统; hadoop dfs只能适用于HDFS文件系统;
- ;hdfs dfs跟hadoop dfs的命令作用一样,也只能适用于HDFS文件系统。

3.7.1HDFS常用命令

实例:

hadoop fs -ls <path>:显示<path>指定的文件的详细信息

hadoop fs -mkdir <path>:创建<path>指定的文件夹

3.7.1HDFS常用命令

实例:

hadoop fs -cat <path>:将<path>指定的文件的内容输出到标准输出(stdout)hadoop fs -copyFromLocal <localsrc> <dst>:将本地源文件<localsrc> 复制到路径<dst>指定的文件或文件夹中

```
administrator@ubuntu:~/hadoop/hadoop-1.2.1/bin$ ./hadoop fs -copyFromLocal /home/administrator/t
empfile/* hdfs://127.0.0.1:9000/tempDir
administrator@ubuntu:~/hadoop/hadoop-1.2.1/bin$ ./hadoop fs -ls hdfs://127.0.0.1:9000/tempDir/
Found 8 items
-rw-r--r-- 1 administrator supergroup
                                                18 2015-04-26 16:48 /tempDir/file1.txt
-rw-r--r-- 1 administrator supergroup
                                                14 2015-04-26 16:48 /tempDir/file1.txt~
                                                18 2015-04-26 16:48 /tempDir/file2.txt
rw-r--r-- 1 administrator supergroup
            1 administrator supergroup
                                                18 2015-04-26 16:48 /tempDir/file3.txt
                                                18 2015-04-26 16:48 /tempDir/file4.abc
rw-r--r-- 1 administrator supergroup
                                                18 2015-04-26 16:48 /tempDir/file5.abc
rw-r--r-- 1 administrator supergroup
                                                17 2015-04-26 16:48 /tempDir/testFile
            1 administrator supergroup
- CM - C - - C - -
            1 administrator supergroup
                                                 0 2015-04-26 16:48 /tempDir/testFile~
administrator@ubuntu:~/hadoop/hadoop-1.2.1/bin$ ./hadoop fs -cat hdfs://127.0.0.1:9000/tempDir
this is file1.txt
this is file1
this is file2.txt
this is file3.txt
this is file4.abc
this is file5.abc
welcome to DBLab
```

3.7.2HDFS的Web界面

在配置好Hadoop集群之后,可以通过浏览器登录

"http://[NameNodelP]:50070"访问HDFS文件系统



利用Java API与HDFS进行交互

实例: 利用hadoop的java api检测伪分布式文件系统HDFS上是否有某文件?

准备工作: 在系统中安装和配置Eclipse

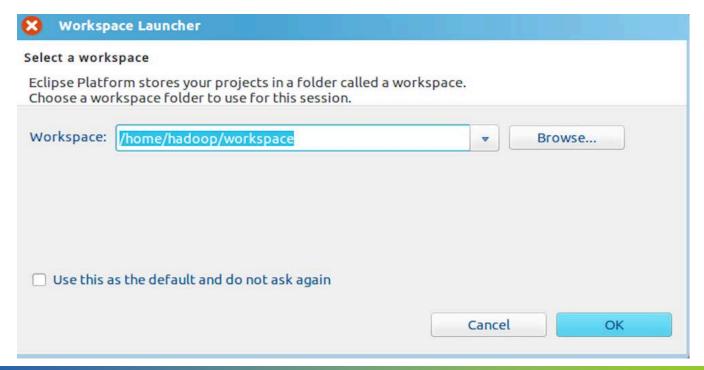
第一步:放置配置文件到当前工程下面(eclipse工作目录的bin文件夹下面)

第二步:编写实现代码

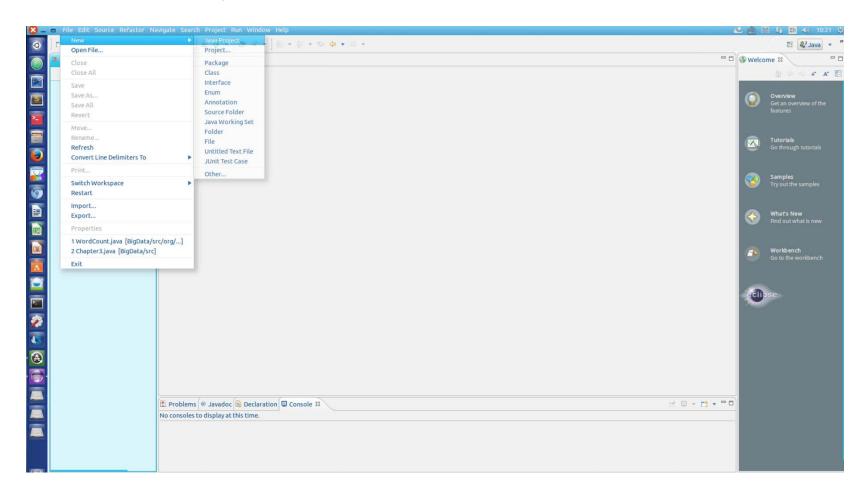
利用Java API进行交互,可以使用软件Eclipse编写Java程序。

- (1) 在虚拟机中安装Eclipse
- (2) 在Eclipse创建项目

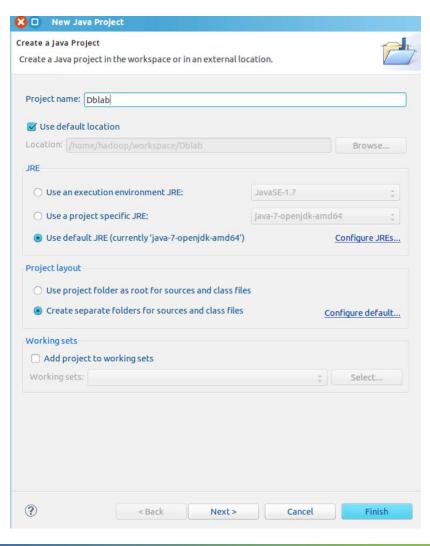
第一次打开Eclipse,需要填写workspace(工作空间),用来保存程序所在的位置,这里按照默认,不需要改动,如下图



点击 "OK"按钮,进入Eclipse软件。开始创建项目,选择顶部菜单File—>New—>Java Project,如下图



输入项目名称 "Dblab",其他不用改动,点击 "Finish"按钮即可。



为项目加载所需要用到的jar包

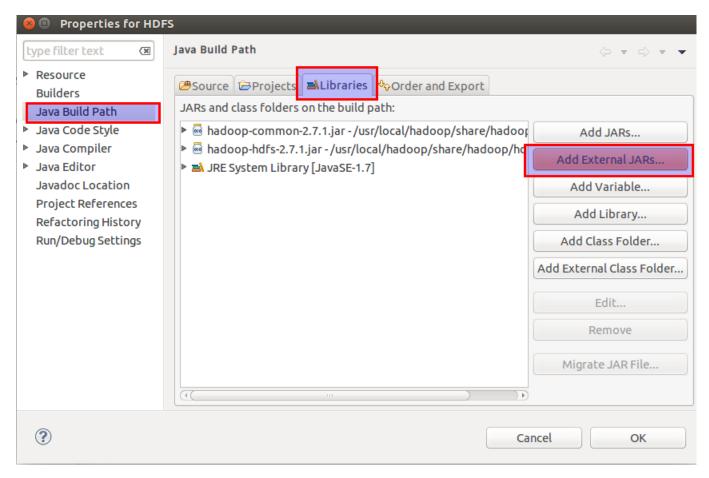
如何获取jar包

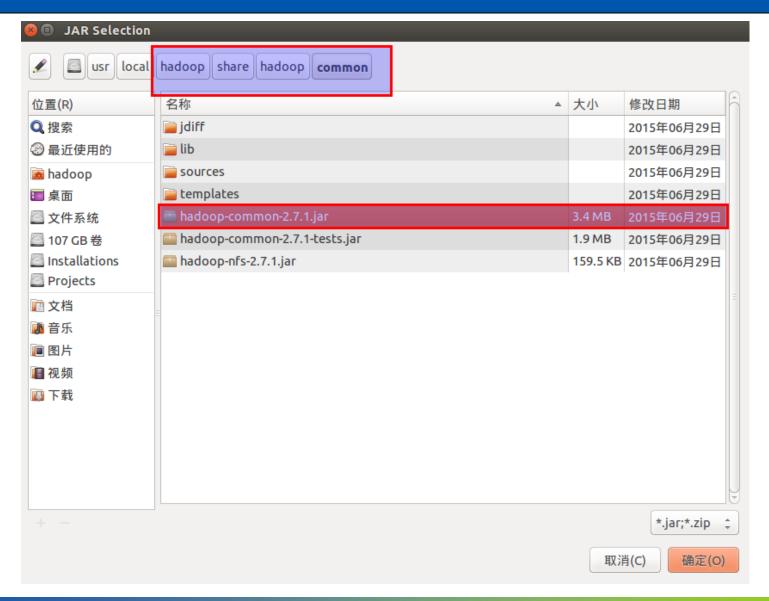
Java API所在的jar包都在已经安装好的hadoop文件夹里

,路径:/usr/local/hadoop/share/hadoop(如果安装的

hadoop不在此目录,请找到jar包所在的文件夹)

在所在项目中加载jar包,具体操作如下:在所选的Eclipse项目(Dblab)上右键点击—>弹出菜单中选择>Properties—>Java Build Path—>Libraries—>Add External JARS





《大数据技术及应用》

编程实例

利用Hadoop 的Java API检测伪分布式文件系统HDFS上是否存在某个文件?

下面编写一个简单的程序来测试伪分布式文件系统 HDFS上是否存在input.txt文件?

第一步:放置配置文件到当前工程下面 需要把集群上的core-site.xml和hdfs-site.xml(这两文件存在/hadoop/etc/hadoop目录下)放到当前工程项目下,即eclipse工作目录的bin文件夹下面。

\$ Wrong FS: hdfs://localhost:9000/user/hadoop/input/input.txt, expected: file:///

第二步:编写实现代码

```
import org.apache.hadoop.conf.Configuration
import org.apache.hadoop.fs.FileSystem
import org.apache.hadoop.fs.Path
public class Chapter3 {
  public static void main(String[] args) {
      try {
        String filename = "hdfs://localhost:9000/user/hadoop/test.txt";
        Configuration conf = new Configuration();
        FileSystem fs = FileSystem.get(conf);
        if(fs.exists(new Path(filename))){
           System.out.println("文件存在");
        }else{
           System.out.println("文件不存在");
    } catch (Exception e) {
       e.printStackTrace();
```

本章小结

- HDFS开源实现了GFS,可以利用由廉价硬件构成的计算机集群。
- HDFS具有兼容廉价的硬件设备、流数据读写、大数据集、简单的文件模型、强大的跨平台兼容性等特点。但是,也要注意到,HDFS也有自身的局限性,比如不适合低延迟数据访问、无法高效存储大量小文件和不支持多用户写入及任意修改文件等。
- 块是HDFS核心的概念,一个大的文件会被拆分成很多个块。HDFS采用抽象的块概念,支持大规模文件存储、简化系统设计、适合数据备份等优点。
- HDFS采用了主从(Master/Slave)结构模型,一个HDFS集群包括一个名称 节点和若干个数据节点。名称节点负责管理分布式文件系统的命名空间;数 据节点是分布式文件系统HDFS的工作节点,负责数据的存储和读取。
- HDFS采用了冗余数据存储,增强了数据可靠性,加快了数据传输速度。 HDFS还采用了相应的数据存放、数据读取和数据复制策略,来提升系统整体 读写响应性能。HDFS把硬件出错看作一种常态,设计了错误恢复机制。
- HDFS的数据读写过程以及HDFS编程实践方面的相关知识。